

Cálculo Numérico A

Capítulo 5 – Resolução de Sistemas de Equações Lineares

Introdução

Métodos diretos: método de Gauss com escolha parcial de pivot

Normas vetoriais e normas matriciais

Condicionamento de um sistema

Métodos iterativos: caso geral

Métodos de Jacobi, de Gauss-Seidel

Introdução

Seja $AX = B$ um sistema de equações, possível e determinado, com a forma matricial

$$\underbrace{\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix}}_A \underbrace{\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}}_X = \underbrace{\begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}}_B$$

onde

$A \in \mathcal{M}_{n \times n}$ é a matriz dos coeficientes;

$B \in \mathcal{M}_{n \times 1}$ é o vetor dos termos independentes;

$X \in \mathcal{M}_{n \times 1}$ é o vetor das incógnitas.

- Os **métodos diretos**, como a regra de Cramer e o método de Gauss, já anteriormente estudados em Álgebra Linear e Geometria Analítica, permitem resolver este tipo de sistemas de equações e obter a solução exata, desde que essas operações sejam feitas sem erros.
- Contudo, pelo facto de muitas vezes depararmos com sistemas de equações onde o número de equações é elevado, estes métodos podem tornar-se instáveis computacionalmente e conduzir a soluções que nada têm a ver com a realidade.
- Em alternativa, neste capítulo serão estudados métodos para determinar a solução aproximada de sistemas de equações do tipo $AX = B$ designados **métodos iterativos**.

Mas antes vamos relembrar o **método de Gauss**, que consiste em, partindo dum sistema

$$AX = B$$

efetuar operações elementares sobre as linhas da matriz aumentada

$$[A|B]$$

de modo a obter

$$[A'|B']$$

onde A' é uma matriz triangular superior.

A solução do sistema equivalente

$$A'X = B'$$

é obtida por substituição ascendente regressiva, calculando-se

x_n, x_{n-1}, \dots, x_1 .

Partindo então do sistema

$$[A^{(1)}|B^{(1)}] = \left[\begin{array}{cccc|c} a_{11} & a_{12} & \cdots & a_{1n} & b_1 \\ a_{21} & a_{22} & \cdots & a_{2n} & b_2 \\ & \vdots & \ddots & \vdots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} & b_n \end{array} \right]$$

Para que os elementos abaixo da diagonal principal da primeira coluna sejam zero, realizam-se operações elementares que vão originando sistemas equivalentes.

Em primeiro lugar se $a_{11} = 0$, trocam-se as linhas por forma a que $a_{11} \neq 0$. A $a_{11} \neq 0$ chama-se **pivot**.

Depois...

obtém-se o multiplicador $-\frac{a_{21}}{a_{11}}$ e faz-se $-\frac{a_{21}}{a_{11}}L_1 + L_2 \rightarrow L_2$

...

obtém-se o multiplicador $-\frac{a_{n1}}{a_{11}}$ e faz-se $-\frac{a_{n1}}{a_{11}}L_1 + L_n \rightarrow L_n$

por forma a obter a matriz equivalente

$$[A^{(2)}|B^{(2)}] = \left[\begin{array}{cccc|c} a_{11}^{(2)} & a_{12}^{(2)} & \cdots & a_{1n}^{(2)} & b_1^{(2)} \\ 0 & a_{22}^{(2)} & \cdots & a_{2n}^{(2)} & b_2^{(2)} \\ & \vdots & \ddots & \vdots & \vdots \\ 0 & a_{n2}^{(2)} & \cdots & a_{nn}^{(2)} & b_n^{(2)} \end{array} \right]$$

De seguida define-se o novo pivot $a_{22}^{(2)}$ se este for diferente de zero, senão troca-se novamente as linhas e...

obtém-se o multiplicador $-\frac{a_{32}^{(2)}}{a_{22}^{(2)}}$ e faz-se $-\frac{a_{32}^{(2)}}{a_{22}^{(2)}} L_2 + L_3 \rightarrow L_3$

...

obtém-se o multiplicador $-\frac{a_{n2}^{(2)}}{a_{22}^{(2)}}$ e faz-se $-\frac{a_{n2}^{(2)}}{a_{22}^{(2)}} L_2 + L_n \rightarrow L_n$

Ao fim de repetidos $n - 1$ passos (supondo que os pivots são sempre não nulos) obtém-se o sistema de matriz triangular superior

$$[A^{(n)} | B^{(n)}] = \left[\begin{array}{cccc|c} a_{11}^{(n)} & a_{12}^{(n)} & \cdots & a_{1n}^{(n)} & b_1^{(n)} \\ 0 & a_{22}^{(n)} & \cdots & a_{2n}^{(n)} & b_2^{(n)} \\ & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \cdots & a_{nn}^{(n)} & b_n^{(n)} \end{array} \right]$$

A solução do sistema anterior é dada por substituição ascendente regressiva, fazendo:

$$\left\{ \begin{array}{l} x_n = \frac{b_n^{(n)}}{a_{nn}^{(n)}} \\ \dots \\ x_1 = \frac{b_1^{(n)} - \sum a_{1k}^{(n)} x_k}{a_{11}^{(n)}} \end{array} \right.$$

Note-se que se não for possível encontrar um pivot não nulo, isso significa que o sistema não tem solução única.

As operações realizadas não são livres de erros que podem originar grandes variações na solução do sistema.

Veja-se o seguinte exemplo:

Exemplo 1

Considere-se o sistema de equações lineares

$$\begin{bmatrix} 3 & 7 & 57 \\ 11 & 23 & -1 \\ 23 & -27 & 5 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 67 \\ 33 \\ 1 \end{bmatrix}$$

Cuja solução é $x = y = z = 1$.

Resolvendo o sistema pelo método de Gauss, mas introduzindo deliberadamente alguns erros de aproximação nos cálculos intermédios, vem:

$$[A^{(1)}|B^{(1)}] = \left[\begin{array}{ccc|c} 3 & 7 & 57 & 67 \\ 11 & 23 & -1 & 33 \\ 23 & -27 & 5 & 1 \end{array} \right]$$

1. Para a 1ª coluna o pivot é $a_{11} = 3 \neq 0$, logo têm-se os multiplicadores $-\frac{a_{21}}{a_{11}} = -\frac{11}{3} \approx -3.7$ e $-\frac{a_{31}}{a_{11}} = -\frac{23}{3} \approx -7.7$ considerando um arredondamento com apenas uma casa decimal.

Fazendo agora $-3.7L_1 + L_2 \rightarrow L_2$ e $-7.7L_1 + L_3 \rightarrow L_3$ obtém-se

$$[A^{(2)}|B^{(2)}] = \left[\begin{array}{ccc|c} 3 & 7 & 57 & 67 \\ 0 & -3 & -210 & -220 \\ 0 & -81 & -440 & -520 \end{array} \right]$$

Nota: Os valores a vermelho são valores aproximados resultantes dos erros de arredondamento introduzidos.

2. Para a 2ª coluna o pivot é $a_{22} \approx -3 \neq 0$, logo vem o multiplicador $-\frac{a_{32}}{a_{22}} = -\frac{-81}{-3} \approx -27$. Fazendo $-27L_2 + L_3 \rightarrow L_3$ obtém-se a matriz triangular superior

$$[A^{(3)}|B^{(3)}] = \left[\begin{array}{ccc|c} 3 & 7 & 57 & 67 \\ 0 & -3 & -210 & -220 \\ 0 & 0 & 5300 & 5400 \end{array} \right]$$

Donde por substituição regressiva a solução do sistema vem

$$z \approx 1; y \approx 3.3; x \approx -4.3$$

Solução muito diferente da solução real devido a acumulação de erros de arredondamento, sendo de esperar uma diminuição da instabilidade quando se aumentar a exatidão nos cálculos intermédios com o aumentando do número de casas decimais.

A propagação dos erros de arredondamento é mais elevada quando os pivots são muito pequenos, ou seja, quando os multiplicadores são muito elevados. Prova-se que a escolha adequada dos elementos pivot permite diminuir a acumulação de erros de arredondamento dos cálculos intermédios.

Método de Gauss com escolha parcial de pivot

A escolha parcial de pivot consiste em, no início do passo k , do método de Gauss, seleccionar como pivot um elemento tal que:

$$\left| a_{pk}^{(k)} \right| \leq \max_{k \leq i \leq n} \left| a_{ik}^{(k)} \right|$$

Ou seja, em cada coluna deve ser escolhido para pivot, o elemento de maior valor absoluto dessa coluna de forma que os multiplicadores venham o mais pequenos possível em módulo.

Exemplo 2

Voltando ao sistema do exemplo 1

$$[A^{(1)}|B^{(1)}] = \left[\begin{array}{ccc|c} 3 & 7 & 57 & 67 \\ 11 & 23 & -1 & 33 \\ 23 & -27 & 5 & 1 \end{array} \right]$$

1. O pivot a escolher na 1ª coluna será $|23| \geq |11| \geq |3|$.

Neste caso dado que o pivot escolhido está na 3ª linha, não se justifica trocar as linhas, pois podemos manter a 3ª linha e fazer as operações na 1ª e 2ª linhas.

Assim, obtém-se os multiplicadores $-\frac{a_{11}}{a_{31}} = -\frac{3}{23} \approx -0.13$ e

$$-\frac{a_{21}}{a_{31}} = -\frac{11}{23} \approx -0.48 \text{ e faz-se}$$

$$-0.13L_3 + L_1 \rightarrow L_1 \text{ e } -0.48L_3 + L_2 \rightarrow L_2$$

Obtendo-se

$$[A^{(2)}|B^{(2)}] = \left[\begin{array}{ccc|c} 0 & 11 & 56 & 67 \\ 0 & 36 & -3 & 33 \\ 23 & -27 & 5 & 1 \end{array} \right]$$

2. Agora o pivot a escolher na 2ª coluna será $|36| \geq |11|$, logo tem-se o multiplicador $\frac{a_{12}}{a_{22}} = -\frac{11}{36} \approx -0.31$ e fazendo $-0.31L_2 + L_1 \rightarrow L_1$ obtém-se a matriz triangular inferior

$$[A^{(3)}|B^{(3)}] = \left[\begin{array}{ccc|c} 0 & 0 & 57 & 57 \\ 0 & 36 & -3 & 33 \\ 23 & -27 & 5 & 1 \end{array} \right].$$

Donde, por substituição descendente regressiva a solução do sistema vem

$$x = 1; y = 1; z = 1$$

A solução é a correta mesmo com erros de arredondamento equivalentes introduzidos nos cálculos intermédios, ou seja, houve uma melhoria da instabilidade do método de Gauss, pois a propagação expansiva dos erros de arredondamento foi travada.

Relembremos agora a seguinte:

Definição 1

Uma matriz $A_{n \times n} = [a_{ij}]_{i,j=1,2,\dots,n}$ diz-se de **diagonal estritamente dominante** (por linhas) se $|a_{ii}| > \sum_{j=1, j \neq i}^n |a_{ij}|$, $i = 1, 2, \dots, n$.

Teorema 1

Se a matriz A do sistema $AX = B$ é de **diagonal estritamente dominante** (por linhas) então o método de eliminação de Gauss pode ser concretizado sem troca de linhas.

Normas vetoriais e normas matriciais

Definição 2

A norma (**norma vetorial**) de um vetor $X \in \mathbb{R}^n$ é uma aplicação $||\cdot|| : \mathbb{R}^n \rightarrow \mathbb{R}_0^+$ que verifica as seguintes propriedades:

1. $\forall X \in \mathbb{R}^n$, $||X|| \geq 0$ e $||X|| = 0 \Leftrightarrow X = \mathbf{0}$
2. $\forall \alpha \in \mathbb{R}$, $\forall X \in \mathbb{R}^n$, $||\alpha X|| = |\alpha| \cdot ||X||$
3. $\forall X, Y \in \mathbb{R}^n$, $||X + Y|| \leq ||X|| + ||Y||$

Exemplos de normas vetoriais

Considere-se o vetor genérico $X = [x_1 \quad x_2 \quad \dots \quad x_n]^T \in \mathbb{R}^n$.

Então

- $\|X\|_1 = \sum_{i=1}^n |x_i|$;
- $\|X\|_\infty = \max_{1 \leq i \leq n} |x_i|$;
- $\|X\|_2 = \sqrt{\sum_{i=1}^n x_i^2}$ (norma euclideana).

Exemplo 3

Seja $X = [-5 \quad 1 \quad -3 \quad 2]^T$.

Então

- $\|X\|_1 = |-5| + |1| + |-3| + |2| = 11$;
- $\|X\|_\infty = \max\{|-5|, |1|, |-3|, |2|\} = 5$;
- $\|X\|_2 = \sqrt{(-5)^2 + 1^2 + (-3)^2 + 2^2} = \sqrt{39}$ (norma euclideana).

Definição 3 (convergência em \mathbb{R}^n)

Considere-se uma sucessão de vetores

$$\mathbf{x}^{(k)} = \begin{bmatrix} x_1^{(k)} & x_1^{(k)} & \dots & x_n^{(k)} \end{bmatrix}^T \in \mathbb{R}^n, \quad k \in \mathbb{N},$$

e um vetor fixo $\mathbf{v} = \begin{bmatrix} v_1 & v_2 & \dots & v_n \end{bmatrix}^T \in \mathbb{R}^n$.

A sucessão $\mathbf{x}^{(k)}$ converge para \mathbf{v} se

$$\lim_{k \rightarrow +\infty} \|\mathbf{x}^{(k)} - \mathbf{v}\| = 0.$$

Repare-se que

$$\lim_{k \rightarrow +\infty} \mathbf{x}^{(k)} = \mathbf{v} \iff \lim_{k \rightarrow +\infty} x_i^{(k)} = v_i, \quad i = 1, 2, \dots, n.$$

Definição 4

A norma (**norma matricial**) de uma matriz $M \in \mathbb{R}^n \times \mathbb{R}^n$ é uma aplicação $||\cdot|| : \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}_0^+$ que verifica as seguintes propriedades:

1. $\forall M \in \mathbb{R}^n \times \mathbb{R}^n$, $||M|| \geq 0$ e $||M|| = 0 \Leftrightarrow M = \mathbf{0}$;
2. $\forall \alpha \in \mathbb{R}$, $\forall M \in \mathbb{R}^n \times \mathbb{R}^n$, $||\alpha M|| = |\alpha| \cdot ||M||$;
3. $\forall M, N \in \mathbb{R}^n \times \mathbb{R}^n$, $||M + N|| \leq ||M|| + ||N||$;
4. $\forall M, N \in \mathbb{R}^n \times \mathbb{R}^n$, $||MN|| \leq ||M|| \cdot ||N||$.

Definição 5 (Normas matriciais induzidas por normas vetoriais)

Seja $||\cdot|| : \mathbb{R}^n \rightarrow \mathbb{R}_0^+$ uma norma vetorial.

Defina-se a seguinte aplicação:

$$||M||_I = \sup_{X \in \mathbb{R}^n \setminus \{0\}} \frac{||MX||}{||X||} = \max_{||X||=1} ||MX||.$$

- Esta aplicação é uma norma matricial e designa-se por **norma matricial induzida** pela (ou subordinada à) **norma vetorial** $||\cdot||$;
- Propriedade importante destas normas (condição de compatibilidade):

$$||MX|| \leq ||M||_I \times ||X||, \quad \forall M \in \mathbb{R}^n \times \mathbb{R}^n, \quad \forall X \in \mathbb{R}^n$$

Exemplos de normas matriciais induzidas por normas vetoriais

Considere-se uma matriz genérica $M = [m_{ij}]_{i,j=1,2,\dots,n} \in \mathbb{R}^n \times \mathbb{R}^n$.

Então

- $\|M\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |m_{ij}|$ (máximo das somas dos módulos dos elementos por colunas) ;
- $\|M\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |m_{ij}|$ (máximo das somas dos módulos dos elementos por linhas) ;

Observação: As normas matriciais $\|\cdot\|_1$ e $\|\cdot\|_\infty$ são normas induzidas, respetivamente, pelas normas vetoriais $\|\cdot\|_1$ e $\|\cdot\|_\infty$.

Exemplo 4

Sendo $M = \begin{bmatrix} -1 & 0 & 5 \\ -2 & 2 & 3 \\ 0 & 2 & 4 \end{bmatrix}$, tem-se:

- $\|M\|_1 = \max\{3, 4, 12\} = 12$;
- $\|M\|_\infty = \max\{6, 7, 6\} = 7$;

Condicionalamento de um sistema

Seja $AX = B$ um sistema de equações, possível e determinado.

Definição 6

Designamos por **número de condição** da matriz A , relativamente a uma norma $||\cdot||$, a quantidade:

$$k(A) = ||A|| \cdot ||A^{-1}|| .$$

Ao resolver o sistema de equações anterior, poderemos estar na presença de instabilidade numérica, resultante do mau condicionamento do problema que essa resolução acarreta.

Assumindo que nos seria dada uma aproximação \hat{B} do vetor exato B , teríamos uma solução aproximada, \hat{X} , do sistema perturbado $A\hat{X} = \hat{B}$.

As normas vetoriais anteriormente estudadas, sugerem-nos a possibilidade de estabelecer definições de erros vetoriais, semelhantes às que foram estabelecidas no Capítulo 1, para erros escalares.

Definições 7 e 8

Considere-se uma determinada norma vetorial $|| \cdot ||$.

Definam-se as seguintes quantidades

- $||\varepsilon_X|| = ||X - \hat{X}||$ (erro absoluto associado ao vetor aproximado \hat{X});
- $||r_X|| = \frac{||X - \hat{X}||}{||X||} = \frac{||\varepsilon_X||}{||X||}$ (erro relativo associado ao vetor aproximado \hat{X}).

Teorema 2

Seja $AX = B$ um sistema de equações, possível e determinado e $A\hat{X} = \hat{B}$ o correspondente sistema perturbado.

Então verifica-se a seguinte desigualdade, válida para normas matriciais induzidas por normas vetoriais:

$$\frac{\|r_X\|}{\|r_B\|} \leq k(A) .$$

Demonstração

- Tem-se

$$A(X - \hat{X}) = B - \hat{B} \Leftrightarrow A\varepsilon_X = \varepsilon_B \Leftrightarrow \varepsilon_X = A^{-1}\varepsilon_B .$$

Assim,

$$\begin{aligned} \frac{||r_X||}{||r_B||} &= \frac{\frac{||\varepsilon_X||}{||X||}}{\frac{||\varepsilon_B||}{||B||}} = \frac{||\varepsilon_X||}{||X||} \times \frac{||B||}{||\varepsilon_B||} = \frac{||A^{-1}\varepsilon_B||}{||X||} \times \frac{||AX||}{||\varepsilon_B||} \leq \\ &\leq \frac{||A^{-1}|| \cdot ||\varepsilon_B||}{||X||} \times \frac{||A|| \cdot ||X||}{||\varepsilon_B||} = ||A^{-1}|| \cdot ||A|| = k(A) \quad \blacksquare \end{aligned}$$

Conclusão

Do teorema anterior surge naturalmente a seguinte conclusão:

$$k(A) = \|A^{-1}\| \cdot \|A\| \geq \|A^{-1}A\| = \|I\| = 1 ,$$

sendo esta desigualdade verdadeira para qualquer uma das 2 normas matriciais anteriormente citadas e I a matriz identidade.

Uma vez que a matriz I não amplia nem diminui o efeito do erro relativo associado ao vetor \hat{B} no erro relativo associado ao vetor \hat{X} (aliás nenhuma outra matriz diminui esse efeito), conclui-se que quanto maior for $k(A)$, maiores serão os desvios verificados nas componentes do vetor \hat{X} que resultam dos desvios cometidos nas componentes do vetor \hat{B} .

Assim, um sistema de equações do tipo $AX = B$ é mal condicionado se, e só se, $k(A)$ for muito grande, isto é, muito maior que 1.

Exemplo 5

Considere o sistema de equações $AX = B \Leftrightarrow \begin{bmatrix} 4 & 13 \\ 3 & 10 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 26 \\ 20 \end{bmatrix}$ e o sistema de equações “perturbado” $A\hat{X} = \hat{B} \Leftrightarrow \begin{bmatrix} 4 & 13 \\ 3 & 10 \end{bmatrix} \begin{bmatrix} \hat{x} \\ \hat{y} \end{bmatrix} = \begin{bmatrix} 25.9 \\ 20.1 \end{bmatrix}$, cujas soluções são, respetivamente $X = \begin{bmatrix} 0 \\ 2 \end{bmatrix}$ e $\hat{X} = \begin{bmatrix} -2.3 \\ 2.7 \end{bmatrix}$.

Demonstre, utilizando as normas vetoriais e matriciais $\|\cdot\|_1$ e $\|\cdot\|_\infty$, que o sistema inicial é mal condicionado.

Resolução

Tem-se

♦ Para as normas $\|\cdot\|_1$:

$$\|\varepsilon_X\|_1 = \|X - \hat{X}\|_1 = \|[x - \hat{x} \quad y - \hat{y}]^T\|_1 = \|[2.3 \quad -0.7]^T\|_1 = 3.0$$

e

$$\|r_X\|_1 = \frac{\|\varepsilon_X\|_1}{\|X\|_1} = \frac{3.0}{2} = 1.5 .$$

Por outro lado,

$$\|\varepsilon_B\|_1 = \|B - \hat{B}\|_1 = \|[0.1 \quad -0.1]^T\|_1 = 0.2$$

e

$$\|r_B\|_1 = \frac{\|\varepsilon_B\|_1}{\|B\|_1} = \frac{0.2}{46} = \frac{1}{230} .$$

Assim, $\frac{\|r_x\|_1}{\|r_B\|_1} = \frac{1.5}{\frac{1}{230}} = 345 \gg 1$, pelo que se conclui imediatamente que o sistema inicial é mal condicionado.

Nota: Repare-se que $345 \leq k_1(A) = \|A^{-1}\|_1 \times \|A\|_1 =$

$$= \left\| \begin{bmatrix} 10 & -13 \\ -3 & 4 \end{bmatrix} \right\|_1 \times \left\| \begin{bmatrix} 4 & 13 \\ 3 & 10 \end{bmatrix} \right\|_1 = 17 \times 23 = 391,$$

como era de esperar.

♦ Para as normas $||\cdot||_\infty$:

$$||\varepsilon_X||_\infty = ||X - \hat{X}||_\infty = ||[x - \hat{x} \quad y - \hat{y}]^T||_\infty = ||[2.3 \quad -0.7]^T||_\infty = 2.3$$

e

$$||r_X||_\infty = \frac{||\varepsilon_X||_\infty}{||X||_\infty} = \frac{2.3}{2} = 1.15 .$$

Por outro lado,

$$||\varepsilon_B||_\infty = ||B - \hat{B}||_\infty = ||[0.1 \quad -0.1]^T||_\infty = 0.1$$

e

$$||r_B||_\infty = \frac{||\varepsilon_B||_\infty}{||B||_\infty} = \frac{0.1}{26} = \frac{1}{260} .$$

Assim, $\frac{||r_X||_\infty}{||r_B||_\infty} = \frac{1.15}{\frac{1}{260}} = 299 \gg 1$, pelo que se conclui, mais uma vez

que o sistema inicial é mal condicionado.

Nota: Repare-se que $299 \leq k_{\infty}(A) = \|A^{-1}\|_{\infty} \times \|A\|_{\infty} =$

$$= \left\| \begin{bmatrix} 10 & -13 \\ -3 & 4 \end{bmatrix} \right\|_{\infty} \times \left\| \begin{bmatrix} 4 & 13 \\ 3 & 10 \end{bmatrix} \right\|_{\infty} = 23 \times 17 = 391,$$

como mais uma vez era de esperar.

Métodos iterativos: caso geral

A resolução direta de um sistema de equações, possível e determinado, do tipo $AX = B$, pode envolver um número muito elevado de equações e consequente efeito indesejado na obtenção do vetor solução X^* , por acumulação de erros de arredondamento no algoritmo computacional utilizado.

Outro efeito indesejado pode surgir pelo simples facto de pequenas variações nos valores das componentes do vetor B (as quais estão associadas a um erro relativo pequeno) poderem originar grandes variações nos valores das componentes do vetor solução X^* (as quais estão associadas a um erro relativo grande).

Para ultrapassar estes obstáculos, podemos utilizar um método de aproximações sucessivas do vetor solução X^* , designado por **método iterativo geral** que consiste em obter sucessivos vetores $X^{(j)}$, $j = 0, 1, \dots$, que se pretende serem elementos de uma sucessão convergente para X^* .

A ideia base consiste em transformar o sistema de equações $AX = B$ num sistema de equações **equivalente** do tipo $X = GX + H$, onde G é designada por **matriz de iteração**.

Tem-se $G \in \mathbb{R}^n \times \mathbb{R}^n$ e $H \in \mathbb{R}^n$.

Os vetores são então obtidos recursivamente, a partir da forma

$$\begin{cases} X^{(0)} \\ X^{(j+1)} = GX^{(j)} + H, \quad j = 0, 1, \dots \end{cases}.$$

A sucessão de vetores $X^{(j)}$, atrás definida, é convergente se, para qualquer vetor inicial $X^{(0)}$, convergir para X^* .

Assim sendo o limite desta sucessão, caso seja convergente, é a solução do sistema de equações $X = GX + H$ e, por conseguinte, também a solução do sistema de equações $AX = B$.

É válido o teorema que se segue.

Teorema 3 (Condição suficiente de convergência do método iterativo geral)

Seja $||\cdot||$ uma norma matricial, induzida por uma norma vectorial, para a qual se tem $||G|| < 1$.

Então, o método iterativo,

$$X^{(j+1)} = GX^{(j)} + H, \quad j = 0, 1, \dots,$$

converge para um vector X^* e tem-se

- $||X^* - X^{(j)}|| \leq \frac{||G||^j}{1-||G||} ||X^{(1)} - X^{(0)}||$ (fórmula do erro *a priori*);
- $||X^* - X^{(j)}|| \leq \frac{||G||}{1-||G||} ||X^{(j)} - X^{(j-1)}||$ (fórmula do erro *a posteriori*).

Notas

- Um método convergente relativamente a uma determinada norma vectorial é também convergente relativamente a qualquer outra norma vectorial;

Na prática, para a obtenção da matriz G , é usual partir do sistema de equações inicial $AX = B$ e escolher uma decomposição da matriz A da forma $A = N - P$, sendo N e P matrizes com a mesma ordem que A , tendo a matriz N a particularidade de ser invertível (regular).

A justificação para este procedimento é a seguinte:

$$\begin{aligned}
& \mathbf{AX} = \mathbf{B} \quad \Leftrightarrow \\
& \Leftrightarrow (\mathbf{N} - \mathbf{P})\mathbf{X} = \mathbf{B} \quad \Leftrightarrow \\
& \Leftrightarrow \mathbf{NX} - \mathbf{PX} = \mathbf{B} \quad \Leftrightarrow \\
& \Leftrightarrow \mathbf{NX} = \mathbf{PX} + \mathbf{B} \quad \Leftrightarrow \\
& \Leftrightarrow \underbrace{\mathbf{N}^{-1}\mathbf{N}}_{\mathbf{I}_n} \mathbf{X} = \mathbf{N}^{-1}(\mathbf{PX} + \mathbf{B}) \quad \Leftrightarrow \\
& \Leftrightarrow \mathbf{X} = \mathbf{N}^{-1}\mathbf{PX} + \mathbf{N}^{-1}\mathbf{B} .
\end{aligned}$$

A partir da igualdade

$$\mathbf{X} = \underbrace{\mathbf{N}^{-1}\mathbf{P}}_{\mathbf{G}} \mathbf{X} + \underbrace{\mathbf{N}^{-1}\mathbf{B}}_{\mathbf{H}} ,$$

Constrói-se a sucessão de vetores:

$$\begin{cases} X^{(0)} \in \mathbb{R}^n \\ X^{(j)} = GX^{(j-1)} + H, \quad j = 1, 2, \dots \end{cases}.$$

Exemplo 6

Considere o sistema de equações $AX = B$, onde

$$A = \begin{bmatrix} 5 & -1 & 2 \\ 1 & 2 & 0 \\ 1 & 6 & -4 \end{bmatrix}, X = \begin{bmatrix} x \\ y \\ z \end{bmatrix} \text{ e } B = \begin{bmatrix} 10.0 \\ -1.3 \\ -14.5 \end{bmatrix}.$$

Verifique que, com $N = \begin{bmatrix} 5 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & -8 \end{bmatrix}$, o método iterativo geral converge

para $X^* = [0.9 \quad -1.1 \quad 2.2]^T$, solução do sistema acima indicado.

Partindo da iterada inicial $X^{(0)} = [1 \quad -1 \quad 2]^T$, determine $X^{(10)}$.

Resolução

- Tem-se $A = N - P \Leftrightarrow P = N - A \Leftrightarrow$

$$P = \begin{bmatrix} 5 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & -8 \end{bmatrix} - \begin{bmatrix} 5 & -1 & 2 \\ 1 & 2 & 0 \\ 1 & 6 & -4 \end{bmatrix} = \begin{bmatrix} 0 & 1 & -2 \\ -1 & 0 & 0 \\ -1 & -6 & -4 \end{bmatrix}.$$

$$\text{Então } G = N^{-1}P = \begin{bmatrix} \frac{1}{5} & 0 & 0 \\ 0 & \frac{1}{2} & 0 \\ 0 & 0 & -\frac{1}{8} \end{bmatrix} \begin{bmatrix} 0 & 1 & -2 \\ -1 & 0 & 0 \\ -1 & -6 & -4 \end{bmatrix} = \begin{bmatrix} 0 & \frac{1}{5} & -\frac{2}{5} \\ -\frac{1}{2} & 0 & 0 \\ \frac{1}{8} & \frac{3}{4} & \frac{1}{2} \end{bmatrix}$$

e

$$H = N^{-1}B = \begin{bmatrix} \frac{1}{5} & 0 & 0 \\ 0 & \frac{1}{2} & 0 \\ 0 & 0 & -\frac{1}{8} \end{bmatrix} \begin{bmatrix} 10.0 \\ -1.3 \\ -14.5 \end{bmatrix} = \begin{bmatrix} 2.0 \\ -0.65 \\ 1.8125 \end{bmatrix}.$$

Então, apesar de se verificar $\|G\|_{\infty} = 1.375$, tem-se $\|G\|_1 = 0.95$, pelo que, sendo $\|G\|_1 < 1$, se confirma a convergência da sucessão

$$\begin{cases} X^{(0)} = [1 & -1 & 2]^T \\ X^{(j)} = GX^{(j-1)} + H, & j = 1, 2, \dots \end{cases}$$

para X^* .

Tem-se, finalmente,

$$\left\{ \begin{array}{l} X^{(0)} = [1 \quad -1 \quad 2]^T \\ X^{(1)} = [1 \quad -1.15 \quad 2.1875]^T \\ X^{(2)} = [0.895 \quad -1.15 \quad 2.16875]^T \\ \vdots \\ X^{(10)} = [0.901057 \quad -1.10080515625 \quad 2.1970778515625]^T \end{array} \right. .$$

Métodos de Jacobi, de Gauss-Seidel e de Relaxação

Os métodos de **Jacobi** e de **Gauss-Seidel** são exemplos de casos particulares do método iterativo geral.

Considerando novamente um sistema de equações do tipo $AX = B$, ambos se baseiam na decomposição específica da matriz

$A = [a_{ij}]_{i,j=1,\dots,n}$ ($a_{ii} \neq 0$, $i = 1, \dots, n$) do tipo

$$A = D + L + U,$$

onde as matrizes D (de diagonal matrix), L (de strictly lower triangular matrix), e U (de strictly upper triangular matrix), são definidas como se segue:

$$D = \begin{bmatrix} a_{11} & 0 & \cdots & 0 \\ 0 & a_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & a_{nn} \end{bmatrix}, \quad L = \begin{bmatrix} 0 & 0 & \cdots & 0 \\ a_{21} & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{n,n-1} & 0 \end{bmatrix}$$

e

$$U = \begin{bmatrix} 0 & a_{12} & \cdots & a_{1n} \\ 0 & 0 & \cdots & \vdots \\ \vdots & \vdots & \ddots & a_{n-1,n} \\ 0 & 0 & \cdots & 0 \end{bmatrix}.$$

Método de Jacobi

No método de **Jacobi**, temos

$$\begin{aligned}AX &= B \quad \Leftrightarrow \\ \Leftrightarrow \left(\underbrace{D}_{\tilde{N}} + \underbrace{L+U}_{-P} \right) X &= B \quad \Leftrightarrow \\ \Leftrightarrow DX + (L+U)X &= B \quad \Leftrightarrow \\ \Leftrightarrow DX &= -(L+U)X + B \quad \Leftrightarrow \\ \Leftrightarrow \underbrace{D^{-1}D}_{I_n} X &= D^{-1}[-(L+U)X + B] \quad \Leftrightarrow \\ \Leftrightarrow X &= -D^{-1}(L+U)X + D^{-1}B .\end{aligned}$$

A partir da igualdade

$$X = \underbrace{-D^{-1}(L + U)}_{G_J} X + \underbrace{D^{-1}B}_{H_J} ,$$

construímos a

Sucessão de iteradas (Método de Jacobi)

$$\begin{cases} X^{(0)} \in \mathbb{R}^n \\ X^{(k)} = G_J X^{(k-1)} + H_J , \quad k = 1, 2, \dots \end{cases} .$$

É também possível obter as componentes do vector

$$X^{(k)} = [x_1^{(k)} \quad x_2^{(k)} \quad \dots \quad x_n^{(k)}]^T \text{ de uma forma explícita}$$

$$\left\{ \begin{array}{l} x_1^{(k)} = \frac{b_1 - \sum_{j=2}^n a_{1j} x_j^{(k-1)}}{a_{11}} \\ \vdots \\ x_i^{(k)} = \frac{b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{ij} x_j^{(k-1)}}{a_{ii}} \\ \vdots \\ x_n^{(k)} = \frac{b_n - \sum_{j=1}^{n-1} a_{nj} x_j^{(k-1)}}{a_{nn}} \end{array} \right. , \quad k = 1, 2, \dots ,$$

sendo de salientar que todas as componentes deste vector dependem, única e exclusivamente, de componentes do vector $X^{(k-1)}$.

Exemplo 7

Considere o sistema de equações $AX = B$, sendo $A = \begin{bmatrix} 6 & -1 & 3 \\ 1 & 2 & 0 \\ -1 & 3 & 5 \end{bmatrix}$,

$$X = \begin{bmatrix} x \\ y \\ z \end{bmatrix} \text{ e } B = \begin{bmatrix} 13.1 \\ -1.3 \\ 6.8 \end{bmatrix}.$$

Verifique que a sucessão, gerada pelo método de Jacobi, converge para um vector X^* ($X^* = [0.9 \quad -1.1 \quad 2.2]^T$), solução do sistema acima indicado.

Partindo da iterada inicial $X^{(0)} = [1 \quad -1 \quad 2]^T$, determine $X^{(10)}$ e obtenha um majorante (com 5 casas decimais, devidamente arredondadas), tão pequeno quanto possível, para $\|X^* - X^{(10)}\|_\infty$.

Resolução

- Tem-se

$$D = \begin{bmatrix} 6 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 5 \end{bmatrix}, \quad L = \begin{bmatrix} 0 & 0 & 0 \\ 1 & 0 & 0 \\ -1 & 3 & 0 \end{bmatrix} \quad \text{e} \quad U = \begin{bmatrix} 0 & -1 & 3 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}.$$

Então

$$G_J = -D^{-1}(L + U) = \begin{bmatrix} 0 & \frac{1}{6} & -\frac{1}{2} \\ -\frac{1}{2} & 0 & 0 \\ \frac{1}{5} & -\frac{3}{5} & 0 \end{bmatrix}$$

e

$$H_J = D^{-1}B = \begin{bmatrix} \frac{131}{60} \\ -\frac{13}{20} \\ \frac{34}{25} \end{bmatrix} = \begin{bmatrix} 2.18(3) \\ -0.65 \\ 1.36 \end{bmatrix}.$$

Como $\|G_J\|_\infty = 0.8 < 1$, conclui-se que a sucessão definida por

$$X^{(k)} = G_J X^{(k-1)} + H_J, \quad k = 1, 2, \dots,$$

converge para X^* , $\forall X^{(0)} \in \mathbb{R}^3$.

Tem-se, finalmente,

$$\left\{ \begin{array}{l} X^{(0)} = [1 \quad -1 \quad 2]^T \\ X^{(1)} = [1.01(6) \quad -1.15 \quad 2.16]^T \\ X^{(2)} = [0.911(6) \quad -1.158(3) \quad 2.25(3)]^T \\ \vdots \\ X^{(9)} = [0.898266521 \dots \quad -1.098800513 \dots \quad 2.200133283 \dots]^T \\ X^{(10)} = [0.900133272 \dots \quad -1.099133260 \dots \quad 2.198933612 \dots]^T \end{array} \right. .$$

Como

$$\begin{aligned} \Delta X^{(9)} &= X^{(10)} - X^{(9)} = \\ &= [0.001866751 \dots \quad -0.000332747 \dots \quad -0.001199671 \dots]^T , \end{aligned}$$

tem-se

$||\Delta X^{(9)}||_{\infty} = 0.001866751 \dots$, pelo que, segundo a fórmula do erro à *posteriori*, se tem

$$\begin{aligned} ||X^* - X^{(10)}||_{\infty} &\leq \frac{||G_J||_{\infty}}{1-||G_J||_{\infty}} ||\Delta X^{(9)}||_{\infty} = \\ &= \frac{0.8}{1-0.8} \times 0.001866751 \dots \leq 0.007467004 \dots < 0.00747. \end{aligned}$$

Conclui-se, desta forma, que todas as coordenadas de $X^{(10)}$ distam das correspondentes coordenadas de X^* de uma quantidade inferior a 0.00747.

Método de Gauss-Seidel

No método de **Gauss-Seidel** , temos

$$\begin{aligned}AX &= B \quad \Leftrightarrow \\ \Leftrightarrow \left(\underbrace{D + L}_N + \underbrace{U}_{-P} \right) X &= B \quad \Leftrightarrow \\ \Leftrightarrow (D + L)X + UX &= B \quad \Leftrightarrow \\ \Leftrightarrow (D + L)X &= -UX + B \quad \Leftrightarrow \\ \Leftrightarrow \underbrace{(D + L)^{-1}(D + L)}_{I_n} X &= (D + L)^{-1}[-UX + B] \quad \Leftrightarrow \\ \Leftrightarrow X &= -(D + L)^{-1}UX + (D + L)^{-1}B .\end{aligned}$$

A partir da igualdade

$$X = \underbrace{-(D + L)^{-1}U}_{G_{GS}} X + \underbrace{(D + L)^{-1}B}_{H_{GS}},$$

construímos a

Sucessão de iteradas (Método de Gauss-Seidel)

$$\begin{cases} X^{(0)} \in \mathbb{R}^n \\ X^{(k)} = G_{GS}X^{(k-1)} + H_{GS} \quad , \quad k = 1, 2, \dots \end{cases}$$

Tal como no método de Jacobi, é também possível obter as componentes do vector $X^{(k)} = [x_1^{(k)} \quad x_2^{(k)} \quad \dots \quad x_n^{(k)}]^T$ de uma forma explícita.

Assim, tem-se

$$x_i^{(k)} = \frac{b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k)} - \sum_{j=i+1}^n a_{ij}x_j^{(k-1)}}{a_{ii}}, \quad k = 1, 2, \dots, \quad i = 1, 2, \dots, n,$$

sendo de salientar que as componentes deste vector dependem não só de componentes do vector $X^{(k-1)}$, mas também de componentes do próprio vector $X^{(k)}$ que está a ser construído.

Exemplo 8

Considere novamente o sistema de equações $AX = B$, sendo

$$A = \begin{bmatrix} 6 & -1 & 3 \\ 1 & 2 & 0 \\ -1 & 3 & 5 \end{bmatrix}, \quad X = \begin{bmatrix} x \\ y \\ z \end{bmatrix} \quad \text{e} \quad B = \begin{bmatrix} 13.1 \\ -1.3 \\ 6.8 \end{bmatrix}.$$

Verifique que a sucessão, gerada pelo método de Gauss-Seidel, converge para um vector X^* ($X^* = [0.9 \quad -1.1 \quad 2.2]^T$), solução do sistema acima indicado. Partindo da iterada inicial $X^{(0)} = [1 \quad -1 \quad 2]^T$, determine $X^{(10)}$ e obtenha um majorante (com 5 casas decimais, devidamente arredondadas), tão pequeno quanto possível, para $\|X^* - X^{(10)}\|_\infty$.

Resolução

- Tem-se

$$D = \begin{bmatrix} 6 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 5 \end{bmatrix}, \quad L = \begin{bmatrix} 0 & 0 & 0 \\ 1 & 0 & 0 \\ -1 & 3 & 0 \end{bmatrix} \quad \text{e} \quad U = \begin{bmatrix} 0 & -1 & 3 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}.$$

Então

$$G_{GS} = -(D + L)^{-1}U = \begin{bmatrix} 0 & \frac{1}{6} & -\frac{1}{2} \\ 0 & -\frac{1}{12} & \frac{1}{4} \\ 0 & \frac{1}{12} & -\frac{1}{4} \end{bmatrix}$$

e

$$H_{GS} = (D + L)^{-1}B = \begin{bmatrix} \frac{131}{60} \\ -\frac{209}{120} \\ \frac{341}{120} \end{bmatrix} = \begin{bmatrix} 2.18(3) \\ -1.741(6) \\ 2.841(6) \end{bmatrix}.$$

Como $\|G_{GS}\|_{\infty} = \frac{2}{3} < 1$, conclui-se que a sucessão definida por

$$X^{(k)} = G_{GS}X^{(k-1)} + H_{GS} \quad , \quad k = 1, 2, \dots \quad ,$$

converge para X^* , $\forall X^{(0)} \in \mathbb{R}^3$.

Tem-se, finalmente,

$$\left\{ \begin{array}{l} X^{(0)} = [1 \quad -1 \quad 2]^T \\ X^{(1)} = [1.01(6) \quad -1.158(3) \quad 2.258(3)]^T \\ X^{(2)} = [0.86(1) \quad -1.080(5) \quad 2.180(5)]^T \\ \vdots \\ X^{(9)} = [0.900017781 \dots \quad -1.100008890 \dots \quad 2.200008890 \dots]^T \\ X^{(10)} = [0.899994072 \dots \quad -1.099997036 \dots \quad 2.198933612 \dots]^T \end{array} \right. .$$

Como

$$\begin{aligned} \Delta X^{(9)} &= X^{(10)} - X^{(9)} = \\ &= [-0.000023709 \dots \quad 0.000018545 \dots \quad 0.000018545 \dots]^T , \end{aligned}$$

então

$||\Delta X^{(9)}||_{\infty} = 0.000023709 \dots$, pelo que, segundo a fórmula do erro *à posteriori*, se tem

$$\begin{aligned} ||X^* - X^{(10)}||_{\infty} &\leq \frac{||G_{GS}||_{\infty}}{1 - ||G_{GS}||_{\infty}} ||\Delta X^{(9)}||_{\infty} = \\ &= \frac{\frac{2}{3}}{1 - \frac{2}{3}} \times 0.000023709 \dots \leq 0.000047418 \dots < 0.00005. \end{aligned}$$

Conclui-se, desta forma, que todas as coordenadas de $X^{(10)}$ distam das correspondentes coordenadas de X^* de uma quantidade inferior a 0.00005.

Demonstra-se que, se uma matriz A for de diagonal estritamente dominante, então tem-se

$$\begin{cases} \|G_J\|_{\infty} < 1 \\ \|G_{GS}\|_{\infty} < 1 \end{cases},$$

onde G_J e G_{GS} representam, respetivamente, as matrizes de iteração associadas aos métodos de Jacobi e de Gauss-Seidel.

Estes resultados dão origem aos seguintes teoremas

Teorema 4 (Condição suficiente de convergência para o método de Jacobi)

Considere-se o sistema de equações $AX = B$.

Se a matriz A for de diagonal estritamente dominante, então a sucessão gerada pelo método de **Jacobi** converge para a solução X^* deste sistema.

Teorema 5 (Condição suficiente de convergência para o método de Gauss-Seidel)

Considere-se o sistema de equações $AX = B$.

Se a matriz A for de diagonal estritamente dominante, então a sucessão gerada pelo método de **Gauss-Seidel** converge para a solução X^* deste sistema.